Bloque 5 · guion palabra por palabra

Tutorial · **Opening the Black Box: Mechanistic Interpretability of LLMs** · MICAI 2026 · Bloque 5 “Audit” · Víctor Terrón-Macías · slides 51–70 · 2:10–3:00

Guion para leer en voz alta (modo **SPEECH** de la ventana de presenter, `slides/engine/speech_victor.py`). Incluye el bloque práctico de NB5: la predicción previa, los 22 minutos en parejas y el debrief. Las indicaciones entre corchetes no se leen.

51 Audit: can we trust the judge?

`slide 51 · p3-section · Block 5 · Audit · 0 step(s)`

Español **2:10:00 → 2:10:15.** *[El título se dice y se avanza.]*

Bloque cinco. Una sola pregunta: cuando un LLM juzga, ¿de cuáles de sus veredictos nos podemos fiar?

English **2:10:00 → 2:10:15.** *[Nothing to add to the title. Say it and move.]*

Block five. One question: when an LLM judges, which of its verdicts do we trust?

52 Two tools you already have, one new subject: an LLM judge

slide 52 · p3-open · Block 5 · Audit · 2 step(s)

Español **2:10:15 → 2:11:15.**

Dos herramientas de esta tarde, apuntadas a un objeto nuevo. En pantalla está la última frase de Salvador: un probe lineal sencillo puede igualar a una feature de sparse autoencoder, y el patching prueba de qué depende realmente el modelo.

Esas dos frases son todo el instrumental de los próximos cuarenta minutos. Lo que cambia es a qué las apuntamos: ya no a un completado factual como “Paris”, sino a un *veredicto* de un modelo que actúa como juez.

> PASO 1 · El probe se convierte en una señal de confianza. No la confianza que el juez *dice*, sino la que lleva su estado interno. Y quiero ser cuidadoso con lo que eso es: es un correlato aprendido, no un detector de mentiras. Puede equivocarse, y antes de terminar el bloque lo van a ver fallar.

> PASO 2 · Y la idea del Bloque 2 — intervenir y mirar la salida — se convierte en una prueba de fundamento: ¿este veredicto se apoyó en la evidencia que de verdad importa? Hoy intervenimos sobre el texto de entrada, quitando o sustituyendo la evidencia, que es la forma más simple. Hacer patching de los estados internos de esos tokens es el paso natural siguiente, y hoy no lo hacemos.

English **2:10:15 → 2:11:15.**

Two tools from this afternoon, pointed at a new subject. On screen is Salvador's last line: a plain probe can match a sparse-autoencoder feature, and patching tests what the model actually relies on.

Those two sentences are the whole toolkit for the next forty minutes. What changes is what we point them at — not a factual completion like “Paris”, but a *verdict* from a model acting as a judge.

> STEP 1 · The probe becomes a confidence signal. Not the confidence the judge states, but the confidence its hidden state carries. And I want to be careful about what that is: it is a learned correlate, not a lie detector. It can be wrong, and before the end of the block you will watch it fail.

> STEP 2 · And Block 2's idea — intervene, then watch the output — becomes a grounding check: did this verdict rest on the evidence that actually matters? Today we intervene on the input text, removing or replacing the evidence, which is the simplest form of it. Patching the hidden states of those tokens is the natural next step, and we are not doing it today.

53 An LLM-assisted audit is a grid: every rule against every piece of evidence

slide 53 · p3-grid · Block 5 · Audit · 2 step(s)

Español **2:11:15 → 2:12:15.** *[2 pasos.]*

Una auditoría asistida por un LLM tiene dos cuerpos de texto. En un eje, las reglas: lo que exige un estándar. En el otro, la evidencia: planes, minutas, bitácoras de cambios, commits. El juez responde una celda a la vez: esta regla, contra este documento, ¿cumple o no cumple?

> PASO 1 · Y llena todas las celdas. Rápido, barato e incansable. Los tamaños de aquí son ilustrativos; una auditoría real son decenas de reglas contra cientos de documentos, o sea miles de veredictos.

> PASO 2 · Nadie revisa todos esos. Lo que significa que la pregunta no es "¿el juez es exacto en promedio?". La pregunta es: *¿cuáles veredictos necesitan una persona?*

Ese cambio de pregunta es todo el bloque. La exactitud promedio es un número que reportas. Una decisión de ruteo es un número que tienes que defender.

[Pregunta: "¿cómo decidirían ustedes qué celdas revisar?". Toma una o dos respuestas — muestra aleatoria, las de baja confianza — y avanza.]

English **2:11:15 → 2:12:15.** *[2 steps.]*

An LLM-assisted audit has two bodies of text. Rules on one axis — what a standard requires. Evidence on the other — plans, minutes, change logs, commits. The judge answers one cell at a time: this rule, against this document, compliant or not.

> STEP 1 · And it fills every cell. Fast, cheap and tireless. The sizes here are illustrative; a real audit is tens of rules against hundreds of documents, so thousands of verdicts.

> STEP 2 · Nobody reviews all of those. Which means the question is not "is the judge accurate on average". The question is: *which verdicts need a human?*

That reframing is the whole block. Average accuracy is a number you report. A routing decision is a number you have to defend.

[Ask: "how would you decide which cells to check?" Take one or two answers — random sample, the low-confidence ones — then move.]

54 Our motivating case: process audits of very small software teams

slide 54 · p3-iso · Block 5 · Audit · 0 step(s)

Español **2:12:15 → 2:13:00.**

Dos palabras sobre de dónde sale esto, porque es contexto, no contenido.

Mi trabajo es sobre auditorías de proceso en equipos de software muy pequeños. ISO/IEC 29110 es el estándar de ciclo de vida escrito justamente para esas organizaciones — hasta veinticinco personas — y cubre gestión de proyecto e implementación de software. Y el reporte técnico, 29110-3-1, da las guías de evaluación: se revisa cada práctica esperada contra los registros del propio proyecto. Un evaluador se sienta y lee planes, minutas y bitácoras, regla por regla.

Eso es la rejilla de la slide anterior. Y un equipo de ocho personas no puede pagar un evaluador de tiempo completo, que es exactamente por lo que la asistencia con LLMs es atractiva aquí — y exactamente por lo que la confianza es el problema que amarra todo.

No voy a citar el estándar: su texto tiene licencia. La regla que van a ver es inventada, escrita en su estilo.

English **2:12:15 → 2:13:00.**

A word on where this comes from, because it is context, not content.

My work is on process audits of very small software teams. ISO/IEC 29110 is the lifecycle standard written for exactly those organisations — up to twenty-five people — covering project management and software implementation. The technical report, 29110-3-1, gives the assessment guidelines: you check each expected practice against the project's own records. An assessor sits down and reads plans, minutes and change logs, rule by rule.

That is the grid from the previous slide. And a team of eight cannot afford a full-time assessor, which is precisely why LLM assistance is attractive here — and precisely why trust is the binding problem.

I will not quote the standard: its text is licensed. The rule you are about to see is invented, written in its style.

55 One rule, one piece of evidence: is the project compliant?

slide 55 · p3-rule · Block 5 · Audit · 1 step(s)

Español **2:13:00 → 2:13:45.** *[1 paso. Lee las dos cajas en voz alta, despacio: la siguiente slide depende de que la sala las haya oído de verdad.]*

Una regla y una pieza de evidencia. Regla R-PM-07, inventada, en el estilo del estándar. Toda solicitud de cambio se registra; se evalúa su impacto en calendario y en costo; y el cliente la aprueba antes de empezar el trabajo.

Y la evidencia, de la minuta: “Reunión de estatus del 12 de marzo. El cliente pidió agregar exportación a CSV en el módulo de reportes. El líder de desarrollo estima tres días extra; se agrega al Sprint 4. Acción: actualizar el plan de proyecto.”

> PASO 1 · Tres cláusulas. Registrada. Calendario *y costo* evaluados. Aprobación del cliente *antes* de empezar. Quédense con esas tres.

[Manos arriba: ¿cumple o no cumple? Que se comprometan antes de revelar.]

English **2:13:00 → 2:13:45.** *[1 step. Read both boxes aloud, slowly — the next slide depends on the room having actually heard them.]*

One rule, one piece of evidence. Rule R-PM-07, invented, in the style of the standard. Every change request is recorded; its impact on schedule and cost is assessed; and the customer approves it before work on it starts.

And the evidence, from the meeting minutes: “Twelfth of March status meeting. Client asked to add CSV export to the reports module. Dev lead estimates three extra days; added to Sprint 4. Action: update the project plan.”

> STEP 1 · Three clauses. Recorded. Schedule *and cost* assessed. Customer approval *before* work starts. Hold those three in your head.

[Hands up: compliant, or non-compliant? Let them commit before the reveal.]

---

56 The judge is confident — and wrong

slide 56 · p3-verdict · Block 5 · Audit · 2 step(s)

Español **2:13:45 → 2:14:45.** *[2 pasos.]*

El juez dice que cumple. Y su razonamiento suena bien: la solicitud quedó registrada y se evaluó su impacto en el calendario. Es fluido, es específico y cita la evidencia. También nos dice que tiene noventa por ciento de confianza.

> PASO 1 · Aquí está la etiqueta del auditor humano. No cumple. La cláusula uno sí se cumple. La dos se cumple a medias: se evaluó el calendario, el costo nunca se mencionó. Y la tres simplemente no está: el trabajo se metió al Sprint 4 sin ninguna aprobación del cliente.

> PASO 2 · Este es el caso peligroso. No un veredicto confundido, ni uno que titubea: un veredicto confiado, fluido y equivocado. Y si nuestra política de ruteo es “manda a revisión humana los de baja confianza”, usando ese noventa por ciento que el juez se puso solo, este veredicto no lo revisa nadie, nunca.

Ese es el fallo que vamos a intentar atrapar.

English **2:13:45 → 2:14:45.** *[2 steps.]*

The judge says compliant. And its reasoning sounds right: the request was recorded, and its schedule impact was assessed. It is fluent, it is specific, it cites the evidence. It also tells us it is ninety per cent confident.

> STEP 1 · Here is the human auditor's label. Non-compliant. Clause one is met. Clause two is half met — schedule was assessed, cost was never mentioned. And clause three is simply absent: the work went into Sprint 4 with no customer approval at all.

> STEP 2 · So this is the dangerous case. Not a confused verdict, not a hedge — a confident, fluent, wrong verdict. And if our routing policy is “send the low-confidence ones to a human”, using the judge's own ninety per cent, this verdict is never reviewed by anybody.

That is the failure we are going to try to catch.

---

57 A probe on the judge's residual stream disagrees, so a human gets the case

slide 57 · p3-probe · Block 5 · Audit · 2 step(s)

Español **2:14:45 → 2:15:30.** *[2 pasos.]*

Entonces preguntémosle al estado interno del juez en lugar de a sus palabras.

El probe es una lectura lineal sobre el residual stream del juez, tomada en la posición de la respuesta: el último token del prompt, donde el siguiente token va a ser Yes o No. Eso es justo lo que cachea el notebook cinco. Es la herramienta del Bloque 3; lo que cambia es el objetivo: se entrena para predecir "¿este veredicto es correcto?".

> PASO 1 · La aguja se queda en una probabilidad de ser correcto de alrededor de 0.4. El juez nos dijo 0.9. Nuestro umbral de aceptación automática aquí es 0.7, y ese número es ilustrativo.

> PASO 2 · Está por debajo del umbral, así que el caso se rutea a un auditor humano.

Las palabras del modelo decían noventa por ciento. Su estado interno, no. Y fíjense en lo que cuesta esto: un forward pass que ya estábamos haciendo, más un producto punto.

English **2:14:45 → 2:15:30.** *[2 steps.]*

So let us ask the judge's hidden state instead of its words.

The probe is a linear read-out on the judge's residual stream, taken at the answer position — the last prompt token, where the next token is about to be Yes or No. That is exactly what notebook five caches. Block 3's tool; what changes is the target. It is trained to predict "is this verdict correct?"

> STEP 1 · The needle settles at a probability of correctness of about 0.4. The judge told us 0.9. Our threshold for automatic acceptance here is 0.7, and that number is illustrative.

> STEP 2 · Below threshold, so the case is routed to a human auditor.

The model's words said ninety per cent. Its hidden state did not. And notice what this costs: one forward pass we were already doing, plus a dot product.

---

58 Editing the evidence shows the verdict rests on one clue and ignores another

slide 58 · p3-ground · Block 5 · Audit · 3 step(s)

Español **2:15:30 → 2:16:45.** *[3 pasos.]*

Un score nos dice que miremos este veredicto. No nos dice qué tiene de malo. Para eso, intervenir — la idea del Bloque 2, aplicada al texto de entrada. Cambias una pieza de evidencia, dejas todo lo demás fijo, y miras el veredicto.

> PASO 1 · Quitamos la frase de los tres días de estimación. El veredicto se voltea a “no cumple”. Entonces esa sola frase cargaba con la decisión.

> PASO 2 · Ahora la regresamos y agregamos una frase nueva: “El cliente rechazó el cambio.” El veredicto no se mueve. Sigue diciendo que cumple. Un rechazo del cliente debería volverlo “no cumple” de inmediato, y el juez no se da cuenta.

> PASO 3 · Juntemos las dos cosas. La estimación de calendario *sí* es evidencia relevante, para la cláusula dos. El problema es que el veredicto depende solo de ella y es completamente insensible a la cláusula tres, la aprobación. Un auditor nunca aceptaría un veredicto fundamentado así, incluso si de casualidad fuera el correcto.

Esta es una intervención a nivel de texto, y es exactamente lo que hace el paso seis del notebook: se sustituye el extracto por texto irrelevante, o se elimina un segmento, todo precalculado para que corra sin GPU. Hacer patching de los estados internos de esos tokens nos diría *dónde* se lee la pista. Ese es el paso siguiente, y no está en el notebook de hoy.

English **2:15:30 → 2:16:45.** *[3 steps.]*

A score tells us to look at this verdict. It does not tell us what is wrong with it. For that, intervene — Block 2's idea, applied to the input text. Change one piece of evidence, hold everything else fixed, and watch the verdict.

> STEP 1 · Remove the sentence with the three-day estimate. The verdict flips to non-compliant. So that one sentence was carrying the decision.

> STEP 2 · Now put it back, and add a new sentence: “The customer rejected the change.” The verdict does not move. Still compliant. A customer rejection should make this non-compliant immediately, and the judge does not notice.

> STEP 3 · Put those together. The schedule estimate *is* relevant evidence — for clause two. The problem is that the verdict depends on it alone, and is completely insensitive to clause three, the approval. An auditor would never accept a verdict grounded like that, even if it happened to be right.

This is a text-level intervention, and it is exactly what step six of the notebook does: the excerpt is replaced by irrelevant boilerplate, or one segment is dropped, all precomputed so it runs without a GPU. Patching the hidden states of those tokens would tell us *where* the clue is read. That is the next step, and it is not in today's notebook.

59 In one study, a judge's hidden states predicted its errors better than its words

slide 59 · p3-why · Block 5 · Audit · 0 step(s)

Español **2:16:45 → 2:17:30.**

La historia de R-PM-07 que acabo de contarles es inventada. Este resultado no.

Radharapu y colegas entrenan probes lineales sobre los estados internos de jueces de razonamiento, con una pérdida de Brier. Comparados contra la confianza verbalizada y contra métodos de muestreo múltiple, los probes quedaron mejor calibrados, con aproximadamente diez veces menos cómputo. Y en sus experimentos generalizaron a dominios de evaluación que no habían visto.

Quiero tener cuidado con esa última afirmación, porque es muy posible que ustedes la contradigan en la siguiente media hora. En nuestra propia prueba, con nuestros datos, el probe *no* transfirió a reglas que nunca había visto. Así que traten la transferencia como algo que se prueba, no como algo que se hereda.

Su propia advertencia honesta nos sirve: los probes son conservadores, y se quedan cortos de confianza en datos fáciles. Esa es una mala propiedad para un leaderboard y una buena para una auditoría, donde un error que se escapa cuesta mucho más que una revisión innecesaria.

Y la línea base que hay que tener presente: para un juez de Yes/No, la probabilidad que le asigna a su propio token de respuesta es gratis. Cualquier probe tiene que ganarle, o no vale la molestia. La referencia de abajo, los semantic entropy probes, hace el mismo truco para alucinación: predecir incertidumbre con un solo forward pass en lugar de muchas muestras.

English **2:16:45 → 2:17:30.**

The R-PM-07 story I just told you is invented. This result is not.

Radharapu and colleagues train linear probes on the hidden states of reasoning judges, with a Brier-score loss. Compared against verbalized confidence and against multi-sample methods, the probes were better calibrated, at roughly ten times less compute. And in their experiments the probes generalised to evaluation domains they had not seen.

I want to be careful with that last claim, because you may well contradict it in the next half hour. In our own test run, on our data, the probe did *not* transfer to rules it had never seen. So take transfer as something you test, not something you inherit.

Their own honest caveat is interesting for us: the probes are conservative, and under-confident on easy data. That is a bad property for a leaderboard and a good one for an audit, where a missed error costs far more than an unnecessary review.

And the baseline to keep in view: for a Yes/No judge, the probability it assigns to its own answer token is free. Any probe has to beat that, or it is not worth the trouble. The line at the bottom, semantic entropy probes, does the same trick for hallucination: predict uncertainty from one forward pass instead of many samples.

60 A calibrated score turns review into a dial

slide 60 · p3-a10 · Block 5 · Audit · 4 step(s)

Español **2:17:30 → 2:19:30.** *[4 pasos. Pieza central. Di "sintético" en la primera frase.]*

Esta slide es sintética: tres mil veredictos simulados, con un juez de alrededor del setenta y cuatro por ciento de exactitud. La uso porque muestra la forma del problema con claridad, y quiero ser explícito en que ningún número de aquí fue medido.

A la izquierda, un diagrama de confiabilidad. En el eje x, la confianza declarada; en el eje y, qué tan seguido el veredicto resulta correcto. La diagonal es calibración perfecta.

> AL ENTRAR · La confianza verbalizada se acumula entre 0.8 y 1.0, mientras la exactitud se queda cerca de 0.75. Todas las barras quedan muy por debajo de la diagonal: exceso de confianza, de forma sistemática.

> PASO 1 · Las barras del probe se pegan a la diagonal. Cuando dice 0.6, acierta alrededor del sesenta por ciento de las veces.

> PASO 2 · Ahora la gráfica de la derecha, que es la que le importa a un auditor. Aceptamos automáticamente todo veredicto cuyo score esté en el umbral o arriba. La cobertura es la fracción que aceptas automáticamente; el eje vertical es la tasa de error entre los que aceptaste. Pon el umbral bajo y aceptas casi todo — y con eso se escapa cada error.

> PASOS 3-4 · Sube el umbral. Menos aceptaciones automáticas, y muchísimos menos errores escapados. Lean la línea debajo de la gráfica: los errores escapados son veredictos equivocados *y* aceptados automáticamente, como fracción de todos los veredictos — la misma definición que usa el notebook. La línea punteada es nuestro objetivo de ruteo: a lo más diez por ciento de error entre los veredictos aceptados automáticamente. La curva del probe lo alcanza alrededor del treinta y ocho por ciento de cobertura. Rutear con las palabras del propio juez baja del diez por ciento apenas con un ocho por ciento de cobertura, lo cual quiere decir que casi no separa lo correcto de lo incorrecto.

Así que un score calibrado convierte la revisión en una perilla. Tú eliges la cobertura, y el método te dice lo que cuesta. Esa perilla es la que van a construir en el notebook.

[El slider se arrastra con el mouse si alguien pregunta "¿y con 90% de cobertura?"; hacer clic en la gráfica no avanza la slide.]

English **2:17:30 → 2:19:30.** *[4 steps. Centrepiece. Say "synthetic" in the first sentence.]*

This slide is synthetic: three thousand simulated verdicts, with a judge about seventy-four per cent accurate. I use it because it shows the shape of the problem cleanly, and I want to be explicit that no number on it was measured.

On the left is a reliability diagram. Stated confidence on the x-axis, how often the verdict is actually correct on the y-axis. The diagonal is perfect calibration.

> ON ARRIVAL · Verbalized confidence piles up between 0.8 and 1.0, while accuracy stays near 0.75. Every bar sits well below the diagonal: overconfident, systematically.

> STEP 1 · The probe's bars hug the diagonal. When it says 0.6, it is right about sixty per cent of the time.

> STEP 2 · Now the right-hand chart, which is the one an auditor cares about. Auto-accept every verdict whose score is at or above a threshold. Coverage is the share you accept automatically; the vertical axis is the error rate among the ones you accepted. Set the threshold low and you accept nearly everything — and every error escapes with it.

> **STEPS 3–4 ·** Raise the threshold. Fewer automatic acceptances, and far fewer escaped errors. Read the line under the chart: escaped errors are verdicts that are wrong ***and*** auto-accepted, as a share of all verdicts — the same definition the notebook uses. The dashed line is our routing target: at most ten per cent error among auto-accepted verdicts. The probe curve meets it at about thirty-eight per cent coverage. Routing by the judge's own words only gets under ten per cent at about eight per cent coverage — which is to say, it barely separates right from wrong at all.

So a calibrated score turns review into a dial. You choose coverage, and you are told what it costs you. That dial is what you are about to build in the notebook.

[The slider is draggable if someone asks "what about 90% coverage?" — clicks on the chart do not advance the slide.]

---

61 A conformal threshold could bound how many wrong verdicts escape review

slide 61 · p3-conformal · Block 5 · Audit · 3 step(s)

Español **2:19:30 → 2:20:15.** *[3 pasos.]*

Lo que levanta la pregunta obvia: ¿podemos convertir esa perilla en una garantía? Antes de empezar: esta slide es una dirección de investigación, mi línea de tesis — auditorías de calidad y seguridad de proyectos de software asistidas por LLMs — y no un resultado publicado.

> PASO 1 · Empezamos con un conjunto de calibración con etiquetas de referencia. Sesenta veredictos sintéticos, colocados en el eje por score del probe. Gris significa que el juez tuvo razón; rojo, que se equivocó. Casi todo el rojo está en scores bajos. No todo.

> PASO 2 · Definimos un escape: un veredicto equivocado *y* aceptado automáticamente. La regla es la del `crc_threshold` del notebook: se barren los umbrales de abajo hacia arriba y se toma el primero donde la tasa empírica de escapes, más una corrección de muestra finita de uno sobre n más uno, se queda por debajo de tu presupuesto alpha. Con sesenta puntos de calibración esa corrección ya se come 1.6 de un presupuesto de 10 puntos, que es el precio honesto de un conjunto de calibración pequeño.

Si los veredictos nuevos son intercambiables con los de calibración, la tasa *esperada* de escapes en los nuevos es a lo más alpha — en expectativa sobre conjuntos de calibración, no una promesa sobre ninguna auditoría en particular. Y una nota para quien conozca el tema: esto acota los escapes sobre todos los veredictos, no la fracción de errores que se escapan. Con un juez de setenta y cuatro por ciento de exactitud, diez por ciento de todos los veredictos puede seguir siendo una fracción grande de los errores. Alpha se elige con el auditor, no solo.

> PASO 3 · Y ahí está la bisagra. La garantía necesita intercambiabilidad. Un área de proceso nueva de 29110 — o una aserción held-out en el notebook — es exactamente donde ese supuesto se muere. Por eso lo que van a correr ahora es la prueba, no el teorema.

English **2:19:30 → 2:20:15.** *[3 steps.]*

Which raises the obvious question: can we turn that dial into a guarantee? Before I start — this slide is a research direction, my thesis line, LLM-assisted quality and security audits of software projects. It is not a published result.

> STEP 1 · Start with a calibration set that has gold labels. Sixty synthetic verdicts, placed along the axis by probe score. Grey means the judge was right, red means it was wrong. Most of the red sits at low scores. Not all of it.

> STEP 2 · Define an escape: a verdict that is wrong *and* auto-accepted. The rule is the one in the notebook's `crc_threshold`: scan thresholds from low to high and take the first one where the empirical escape rate, plus a finite-sample correction of one over n plus one, stays under your budget alpha. With sixty calibration points that correction already eats 1.6 of a 10-point budget, which is the honest price of a small calibration set.

If new verdicts are exchangeable with the calibration verdicts, the *expected* escape rate on new verdicts is at most alpha — in expectation over calibration sets, not a promise about any single audit. A note for the experts: this bounds escapes over all verdicts, not the share of errors that escape. With a seventy-four per cent accurate judge, ten per cent of all verdicts can still be a large share of the errors. Choose alpha with the auditor, not alone.

> STEP 3 · And there is the hinge. The guarantee needs exchangeability. A new 29110 process area — or a held-out assertion in the notebook — is exactly where that assumption dies. Which is why

> what you are about to run is the test, not the theorem.

---

62 In the notebook, contracts stand in for project records

slide 62 · p3-legal · Block 5 · Audit · 0 step(s)

Español **2:20:15 → 2:21:00.**

No podemos compartir registros de auditoría reales, así que el notebook usa un análogo público con la misma forma.

LegalBench tiene catorce tareas de contract-NLI, derivadas de ContractNLI. Cada tarea es una aserción aplicada a cláusulas de acuerdos de confidencialidad — por ejemplo, si una cláusula establece que la parte receptora puede compartir información confidencial con terceros. El mapeo es exacto: la aserción es mi regla, el extracto del contrato es mi evidencia, y el veredicto es Yes o No.

Y la prueba de cambio de distribución viene incluida en los datos. Once aserciones se parten por documento en train, calibración y test, de modo que ningún contrato de test se vio en entrenamiento. Y luego tres aserciones se dejan fuera *por completo* — aviso sobre divulgación obligada, devolución de información confidencial y supervivencia de obligaciones. Ningún ejemplo de esas reglas en ninguna parte del entrenamiento. Esas tres hacen el papel de un área de proceso nueva que aparece en la auditoría del año que entra.

El veredicto se lee directo de los logits de Yes/No, que es también de donde sale la línea base de probabilidad del token, y los estados internos en el último token del prompt están cacheados — por eso el notebook corre en un runtime de CPU gratuito y nadie necesita GPU.

Que es el notebook que Salvador les pidió abrir cuando me pasó el micrófono. Déjenme confirmarlo aquí: ¿todos con NB5 en pantalla? Corran la primera celda mientras termino esta slide: con un runtime de CPU basta, no necesitan GPU y no hay nada que instalar. Si no lo tienen, es el último notebook de **salvahin.github.io/mechinterp-tutorial**, y el enlace también aparece en la slide del trabajo en un momento. Si quien está a su lado tampoco lo tiene, compartan laptop: con una por pareja sobra.

[Di el enlace despacio, dos veces, y no dejes esta slide hasta que la mayoría de las pantallas muestren Colab. El asistente va con quien se atore. Verifica antes de la sesión qué juez usa de verdad la caché publicada: esta fila dice Gemma 3 4B IT, y los números del debrief son del fallback Qwen2.5-0.5B. Di cuál está corriendo la sala.]

English **2:20:15 → 2:21:00.**

We cannot share real audit records, so the notebook uses a public analogue with the same shape.

LegalBench has fourteen contract-NLI tasks, derived from ContractNLI. Each task is one assertion applied to clauses from non-disclosure agreements — for example, whether a clause states that the receiving party may share confidential information with third parties. So the mapping is exact: the assertion is my rule, the contract excerpt is my evidence, and the verdict is Yes or No.

And the shift test is built into the data. Eleven assertions are split by document into train, calibration and test, so no test contract was seen in training. Then three assertions are held out *entirely* — notice on compelled disclosure, return of confidential information, survival of obligations. No example of those rules anywhere in training. They stand in for a new process area appearing in next year's audit.

The verdict is read straight from the Yes/No logits, which is also where the token-probability baseline comes from, and the hidden states at the last prompt token are cached — which is why the notebook runs on a free CPU runtime and nobody needs a GPU.

Which is the notebook Salvador asked you to open when he handed over. Let me check that here: everyone with NB5 on screen? Run the first cell while I finish this slide — a CPU runtime is fine, you do not need a GPU and there is nothing to install. If you do not have it, it is the last notebook on **salvahin.github.io/mechinterp-tutorial**, and the link is on the hands-on slide in a moment too. If your neighbour is not open either, share a laptop; one per pair is plenty.

[Say the link slowly, twice, and do not leave this slide until most screens show Colab. The assistant goes to whoever is stuck. Check before the session which judge the published cache actually uses: this row says Gemma 3 4B IT, and the debrief numbers are the Qwen2.5-0.5B fallback. Say which one the room is running.]

---

63 Commit to a prediction first

`slide 63 · p3-predict · Block 5 · Audit · 0 step(s)`

Español **2:21:00 → 2:21:30.** *[Compromiso previo. No reveles la respuesta.]*

Antes de que nadie corra nada: comprométanse. Manos arriba por A, B, C y D: ¿qué señal va a ordenar mejor los veredictos equivocados?

[Cuenta cada opción en voz alta y escribe los cuatro números en el pizarrón. Volvemos a ellos en el debrief.]

Las opciones C y D son las interesantes: la probabilidad del token es gratis, ya está en los logits, y un probe que apenas la empata agregó costo y ninguna información. Ahora escriban su propia predicción en la celda Predict del notebook, antes de que aparezca el primer resultado. Equivocarse aquí es justamente el punto del ejercicio.

Si todavía no tienen NB5 abierto en la pantalla, ábranlo ahora — el último notebook de **salvahin.github.io/mechinterp-tutorial** — o asómense a la laptop de al lado.

English **2:21:00 → 2:21:30.** *[Commitment device. Do not reveal the answer.]*

Before anyone runs anything: commit. Hands up for A, B, C, D — which signal will rank wrong verdicts best?

[Count each option out loud and write the four numbers on the whiteboard. We come back to them in the debrief.]

Options C and D are the interesting ones: token probability is free, it is already in the logits, and a probe that merely ties it has added cost and no information. Now write your own prediction in the Predict cell of the notebook, before the first result appears. Being wrong here is the point of the exercise.

If NB5 is not open on your screen yet, open it now — the last notebook on **salvahin.github.io/mechinterp-tutorial** — or look over at your neighbour's.

---

64 NB5: measure whether the judge's hidden state knows when it is wrong

slide 64 · p3-nb5 · Block 5 · Audit · 0 step(s)

Español **2:21:30 → 2:43:30 (22 minutos).** *[Manos a la obra. Di el encuadre, luego deja de hablar y circula.]*

Notebook cinco, el último del sitio; la dirección está en la slide: **salvahin.github.io/mechinterp-tutorial**. Veintidós minutos, en parejas: uno maneja el teclado y el otro lee las celdas en voz alta y predice antes de cada corrida. Con una laptop por pareja basta, con runtime de CPU alcanza, y da igual si en la mañana NB0 no les funcionó: este notebook corre sobre activaciones cacheadas.

Seis pasos. Correr el juez en unos cuantos pares, para haberlo visto funcionar. Entrenar un probe que prediga cuáles de sus veredictos están mal. Comparar ese probe contra las dos líneas base baratas — el número verbalizado y la probabilidad del token — en AUROC y en error de calibración. Elegir un umbral de ruteo que mantenga el error entre los aceptados por debajo del diez por ciento. Luego probar en las tres aserciones held-out. Y al final, quitar la evidencia detrás de los veredictos más confiados y ver si se mueven. Los pasos uno a cuatro son el núcleo, el cinco es el resultado clave, el seis es la prueba de fundamento, y el umbral conformal del final es opcional.

Tres términos, porque los resultados dependen de ellos. AUROC es ordenamiento: la probabilidad de que un veredicto equivocado reciba un score más bajo que uno correcto, así que 0.5 no sirve de nada. ECE es la brecha promedio entre la confianza declarada y la exactitud real. Brier es la brecha cuadrática media contra el resultado real de cero o uno. Y la razón por la que AUROC va primero: recalibrar puede arreglar el ECE, pero nunca puede cambiar el ordenamiento.

Un detalle que se le pasa a todo el mundo: el objetivo es "¿este veredicto está mal?", no "¿la respuesta es Yes?". Así que la confianza tiene que ser la probabilidad de la respuesta que el juez de hecho dio: el máximo entre P(Yes) y P(No). Arranquen; aquí andamos los dos, y mejor pregunten temprano que tarde.

[Circula con el asistente. Avisos de tiempo en voz alta a las 2:30 (deberían ir en el paso 3) y a las 2:37 (paso 5). Si la sala va a medio flujo, toma 2-3 minutos del debrief, nunca del cierre.]

English **2:21:30 → 2:43:30 (22 minutes).** *[Hands-on. Say the frame, then stop talking and circulate.]*

Notebook five, the last one on the site; the address is on the slide: **salvahin.github.io/mechinterp-tutorial**. Twenty-two minutes, in pairs: one person drives, the other reads the cells out loud and predicts before each run. One laptop per pair is all you need, a CPU runtime is enough, and it does not matter whether you got NB0 working this morning — this notebook runs on cached activations.

Six steps. Run the judge on a few pairs, so you have seen it work. Train a probe to predict which of its verdicts are wrong. Compare that probe against the two cheap baselines — the verbalized number and the token probability — on AUROC and on calibration error. Pick a routing threshold that holds error among accepted verdicts under ten per cent. Then test on the three held-out assertions. And finally, remove the evidence behind the most confident verdicts and see whether they move. Steps one to four are core, five is the key result, six is the grounding check, and the conformal threshold at the end is an optional stretch.

Three terms, because the results depend on them. AUROC is ranking: the chance that a wrong verdict scores lower than a right one, so 0.5 is useless. ECE is the average gap between stated confidence and actual accuracy. Brier is the mean squared gap to the actual zero-one outcome. And the reason AUROC comes first: recalibration can fix ECE, but it can never change ranking.

> One subtlety that catches everybody: the target is “is this verdict wrong”, not “is the answer Yes”. So the confidence has to be the probability of whichever answer the judge actually gave — the larger of P(Yes) and P(No). Start now; we are both here, and ask early rather than late.
>
> *[Circulate with the assistant. Time checks out loud at 2:30 (should be at step 3) and 2:37 (step 5). If the room is mid-flow, take 2-3 minutes from the debrief, never from the wrap-up.]*

---

65 What would an auditor accept as evidence that a verdict is safe to skip?

slide 65 · p3-debrief · Block 5 · Audit · 0 step(s)

Español **2:43:30 → 2:48:00.** *[Cinco minutos. Primero sus números, luego los míos.]*

Laptops a medio cerrar. De vuelta al pizarrón: esto es lo que predijo esta sala hace veinte minutos.

[Pide a dos parejas que lean en voz alta su AUROC y su ECE para las tres señales. Esos son los números reales de la sesión: usa esos, no los míos.]

En nuestra propia prueba, con el juez pequeño de respaldo, esto es lo que salió. El juez acierta alrededor del setenta y cinco por ciento en test, y sesenta y cuatro por ciento en las aserciones held-out. Para ordenar los veredictos equivocados: preguntarle al juez qué tan confiado está da 0.43 — peor que el azar, y la razón es casi chistosa: en todo el split de test solo contestó 75, 80, 85 o 95. Tiene cuatro estados de ánimo; ahí no hay nada con qué ordenar. La probabilidad del token da 0.63, y es gratis. El probe da 0.71.

Entonces, ¿dónde ganó el probe? Contra las palabras del juez, de forma contundente — y es una vara baja. Contra la probabilidad del token, sí, pero solo en reglas en las que había sido calibrado, y por 0.71 contra 0.63. Un margen real, y modesto.

¿Dónde falló? En una regla que nunca había visto. Con el umbral que había calibrado, se escapó de revisión el diecisiete y medio por ciento de los veredictos — equivocados y aceptados automáticamente — contra ocho por ciento de la línea base gratis. No es que solo se degradara: terminó *peor que aquello a lo que le había ganado*. Mi lectura, y es una hipótesis, no una medición: puede que el probe haya aprendido cuáles *reglas* son difíciles, en lugar de cuándo el juez está incierto.

Y falló de una segunda forma, independiente. De los cuarenta veredictos Yes más confiados, el setenta por ciento siguió diciendo Yes cuando la evidencia se sustituyó por texto irrelevante — y esos veredictos eran *correctos*. El juez dio la respuesta correcta sin leer la evidencia. La exactitud no puede ver eso. Un score de confianza no puede ver eso. Solo la intervención.

Entonces, ¿qué cuenta como evidencia de que un veredicto se puede saltar sin revisión? Mi respuesta: un score calibrado, solo, no es evidencia. Un score, más una cota declarada de escapes, más una prueba de fundamento sobre una muestra de los aceptados: esa combinación empieza a parecerse a algo que un evaluador podría firmar, porque cada una cubre un fallo que las otras dos no pueden ver.

English **2:43:30 → 2:48:00.** *[Five minutes. Their numbers first, mine second.]*

Laptops half-closed. Back to the whiteboard: here is what this room predicted twenty minutes ago.

[Ask two pairs to read out their AUROC and ECE for the three signals. Those are the session's real numbers — use them, not mine.]

In our own test run, with the small fallback judge, this is what came out. The judge is right about seventy-five per cent of the time on test, and sixty-four per cent on the held-out assertions. For ranking wrong verdicts: asking the judge how confident it is scores 0.43 — worse than chance, and the reason is almost funny, across the whole test split it only ever answered 75, 80, 85 or 95. It has four moods; there is nothing in there to rank with. The token probability scores 0.63, and it is free. The probe scores 0.71.

So: where did the probe win? Against the judge's words, decisively — and that is a low bar. Against token probability, yes, but only on rules it had been calibrated on, and by 0.71 to 0.63. A real margin, and a modest one.

> Where did it fail? On a rule it had never seen. With its calibrated threshold, seventeen and a half per cent of verdicts escaped review — wrong and auto-accepted — against eight per cent for the free baseline. It did not merely degrade; it ended up worse than the thing it beat. My reading, and it is a hypothesis, not a measurement: the probe may have learned which *rules* are hard rather than when the judge is uncertain.
>
> And it failed a second, independent way. Of the forty most confident Yes verdicts, seventy per cent stayed Yes when the evidence was replaced by irrelevant boilerplate — and those verdicts were *correct*. The judge got the right answer without reading the evidence. Accuracy cannot see that. A confidence score cannot see that. Only the intervention can.
>
> So what counts as evidence that a verdict is safe to skip? My answer: a calibrated score alone is not evidence. A score, plus a stated escape bound, plus a grounding check on a sample of accepted verdicts — that combination starts to look like something an assessor could sign, because each one covers a failure the other two cannot see.

---

66 Pick the method from your question, and the validation from the method

slide 66 · p3-map · Block 5 · Audit · 6 step(s)

Español **2:48:00 → 2:49:30.** *[6 pasos, una fila por avance.]*

Un paso atrás: toda la tarde en una tabla. Elige el método desde tu pregunta, y luego elige la validación desde el método — esa segunda mitad es la parte que la gente se salta.

> PASO 1 · ¿Está representado el concepto X? Un probe lineal. Valídalo en splits held-out *y* fuera de distribución, que es exactamente el fallo que acaban de correr.

> PASO 2 · ¿Qué componente causa Y? Activation patching. Revisa que el efecto sobreviva a otras corrupciones, y usa path patching para separar rutas directas de indirectas.

> PASO 3 · ¿Qué features usa? Sparse autoencoders. Y la validación es brutal: si un probe sencillo lo iguala, el SAE no agregó nada.

> PASO 4 · ¿Cómo se computa un prompt concreto? Un attribution graph, que es una hipótesis hasta que intervienes sobre las features que tiene.

> PASO 5 · ¿Puedo controlar el comportamiento Z? Un vector de steering. Y pruébalo contra direcciones ortogonales, porque resulta que las direcciones de steering no son identificables: perturbaciones ortogonales a la tuya pueden lograr buena parte del mismo efecto.

> PASO 6 · Fíjense en lo resaltado. El bloque cinco usó solo las dos primeras filas — y la segunda solo en su forma más simple, interviniendo sobre el texto de entrada y no sobre los estados internos. Las herramientas más simples hicieron el trabajo de auditoría. El patching de estados internos es el paso siguiente obvio, y es hacia allá donde voy.

English **2:48:00 → 2:49:30.** *[6 steps, one row per advance.]*

Stepping back: the whole afternoon in one table. Pick the method from your question, and then pick the validation from the method — that second half is the part people skip.

> STEP 1 · Is concept X represented? A linear probe. Validate on held-out *and* out-of-distribution splits — which is exactly the failure you just ran.

> STEP 2 · Which component causes Y? Activation patching. Check the effect survives other corruptions, and use path patching to separate direct from indirect routes.

> STEP 3 · Which features does it use? Sparse autoencoders. And the validation is blunt: if a plain probe matches it, the SAE added nothing.

> STEP 4 · How is one prompt computed? An attribution graph — which is a hypothesis until you intervene on the features in it.

> STEP 5 · Can I control behaviour Z? A steering vector. And test it against orthogonal directions, because steering directions turn out not to be identifiable: perturbations orthogonal to yours can reach much of the same effect.

> STEP 6 · Note what is highlighted. Block five used only the first two rows — and the second only in its simplest form, intervening on input text rather than on hidden states. The simplest tools did the auditing work. Hidden-state patching is the obvious next step, and that is where I am going.

67 Your turn: map one LLM-judged task from your own research

slide 67 · p3-transfer · Block 5 · Audit · 0 step(s)

Español **2:49:30 → 2:51:30.** *[El canvas impreso está en las mesas: printables/transfer_canvas.pdf.]*

Dos minutos en parejas, y esta es la parte que se lleva fuera de este salón.

Seis casillas. ¿Qué decide el modelo? ¿Quién o qué te da la etiqueta de referencia? ¿De dónde se leería la señal de confianza — qué capa, qué token? ¿Qué tasa de escapes pueden tolerar de verdad? ¿Qué pieza de evidencia *debería* voltear el veredicto, para poder probar el fundamento? Y ¿cuál es su aserción no vista — qué hace el papel de una regla en la que el probe nunca fue calibrado?

Si ustedes juzgan cualquier cosa con un modelo — calificar, etiquetar datos, revisar código, filtrar artículos, verificar afirmaciones contra fuentes — las casillas uno a tres toman unos cinco minutos. Las casillas cuatro a seis son donde están los problemas interesantes. Llenen uno a tres ahora, y cuatro a seis si les da el tiempo.

[Toma un ejemplo de la sala en voz alta antes de avanzar.]

English **2:49:30 → 2:51:30.** *[Printed canvas on the tables: printables/transfer_canvas.pdf.]*

Two minutes in pairs, and this is the part that transfers out of this room.

Six boxes. What does the model decide? Who or what gives you the gold label? Where would the confidence signal be read from — which layer, which token? What escape rate can you actually tolerate? Which piece of evidence *should* flip the verdict, so you can test grounding? And what is your unseen assertion — what plays the role of a rule the probe has never been calibrated on?

If you judge anything with a model — grading, labelling data, reviewing code, screening papers, checking claims against sources — boxes one to three take about five minutes. Boxes four to six are where the interesting problems are. Fill one to three now, and four to six if you have time.

[Take one example from the room out loud before moving on.]

68 From observing models to auditing them — with tools that are still young

slide 68 · p3-field · Wrap · 7 step(s)

Español **2:51:30 → 2:55:00.** *[7 pasos.]*

Dónde está el campo, en un solo arco.

> **PASOS 1-5 ·** Observamos, con el logit lens. Intervenimos, con patching. Descompusimos, con sparse autoencoders. Trazamos, con attribution graphs. Y luego auditamos: un probe sobre un juez. Cada una de esas es una herramienta para convertir un estado interno en una afirmación que se puede poner a prueba.

> **PASO 6 ·** Los problemas abiertos, y no son míos: son del campo, del review de Open Problems. La mayoría de los resultados de circuitos explican un prompt, no un mecanismo general. Los attribution graphs explican un modelo de reemplazo, y qué tan fiel es eso al modelo real está genuinamente abierto. Automatizar interpretabilidad con agentes apenas empieza. Y no hay estándares de evaluación acordados, que es la razón por la que tantos resultados son difíciles de comparar.

> **PASO 7 ·** Y las implicaciones, que son la razón por la que trabajo en esto. Aseguramiento y auditoría de sistemas de IA — el bloque de hoy. Evidencia que un regulador pudiera de verdad pedir. Y usar los modelos como objetos de estudio científico.

Déjenme cerrar la parte técnica con honestidad. Estas herramientas son jóvenes. La mayoría de los resultados publicados son sobre modelos pequeños o prompts individuales. El resultado principal del bloque que acaban de correr fue que mi método perdió contra una línea base gratis en el momento en que cambió la regla. Traten cada interpretación como una hipótesis con una prueba pegada: esa es la disciplina que el campo necesita, y es lo único de esta tarde que más me gustaría que se llevaran.

English **2:51:30 → 2:55:00.** *[7 steps.]*

Where the field is, in one arc.

> **STEPS 1-5 ·** We observed, with the logit lens. We intervened, with patching. We decomposed, with sparse autoencoders. We traced, with attribution graphs. And then we audited — a probe on a judge. Every one of those is a tool for turning an internal state into a claim you can test.

> **STEP 6 ·** The open problems, and these are not mine — they are the field's, from the Open Problems review. Most circuit results explain one prompt, not a general mechanism. Attribution graphs explain a replacement model, and how faithful that is to the real one is genuinely open. Automating interpretability with agents is just starting. And there are no agreed evaluation standards, which is why so many results are hard to compare.

> **STEP 7 ·** And the implications, which is why I work on this. Assurance and audits of AI systems — today's block. Evidence that a regulator could actually ask for. And using models as objects of scientific study.

Let me end the technical part honestly. These tools are young. Most published results are on small models or single prompts. The headline result of the block you just ran was that my method lost to a free baseline the moment the rule changed. Treat every interpretation as a hypothesis with a test attached — that is the discipline the field needs, and it is the one thing from this afternoon I would most like you to keep.

69 Everything we used today is open

slide 69 · p3-res · Wrap · 0 step(s)

Español **2:55:00 → 2:56:00.** *[No leas la lista.]*

Todo lo que usamos es abierto, y esta slide es una referencia, no algo para leer en voz alta.

Columna izquierda: las herramientas de los notebooks y dónde aprender más. Si quieren un curso de verdad y no un tutorial, el capítulo uno de ARENA es el mejor seguimiento gratuito que conozco.

Columna derecha: los artículos sobre los que se construyeron los bloques. El review de Open Problems, abajo, es el mapa de lo que todavía nadie sabe, y es lo más útil de esta slide si andan buscando una pregunta de investigación. Todos estos enlaces están también en el sitio de materiales.

English **2:55:00 → 2:56:00.** *[Do not read the list.]*

Everything we used is open, and this slide is a reference rather than something to read out.

Left column: the tools from the notebooks, and where to learn more. If you want a proper course rather than a tutorial, ARENA chapter one is the best free follow-up I know.

Right column: the papers the blocks were built on. The Open Problems review at the bottom is the map of what nobody knows yet, and it is the most useful thing on this slide if you are looking for a research question. All of these links are on the materials site as well.

---

70 Thank you

slide 70 · p3-thanks · Wrap · 0 step(s)

Español **2:56:00 → 3:00:00.**

Gracias — por tres horas, y por las predicciones que fallaron a propósito.

Esto es trabajo conjunto con Miguel González y Salvador Hinojosa, del Tec de Monterrey, y gracias a nuestro asistente, que mantuvo Colab con vida toda la tarde.

[Agradece al asistente por su nombre.]

Las slides, los seis notebooks y los imprimibles están en el enlace de la pantalla, o escaneen el código. Los notebooks siguen funcionando después de hoy, y el quinto es por donde yo empezaría si ustedes juzgan cualquier cosa con un modelo. Nos quedamos para preguntas — y la que más me interesa es el resultado del cambio de distribución: si creen que el probe está aprendiendo la dificultad de la regla en lugar de la incertidumbre del modelo, me gustaría oír cómo separarían las dos cosas.

[Si alguien pregunta "¿qué herramienta para mi problema?", regresa al mapa de métodos, p3-map.]

English **2:56:00 → 3:00:00.**

Thank you — for three hours, and for the predictions you got wrong on purpose.

This is joint work with Miguel González and Salvador Hinojosa at Tec de Monterrey, and thanks to our student assistant, who kept Colab alive all afternoon.

[Thank the assistant by name.]

Slides, all six notebooks and the printables are at the link on screen, or scan the code. The notebooks keep working after today, and the fifth one is the one I would start with if you judge anything with a model. We will stay for questions — and the one I am most interested in is the shift result: if you think the probe is learning rule difficulty rather than uncertainty, I would like to hear how you would separate the two.

[If someone asks "which tool for my problem", jump back to the method map, p3-map.]

Generado desde slides/deck.html · rehacer con `python3 slides/engine/handout.py` después de reconstruir el deck.